

General overview

Corpus	Date	SL	TL
hplt-v2-en-ml.tsv	1/21/2025	English (en)	Malayalam (ml)

Volumes

Segments	SL tokens	SL characters	SL size
547,168	15M	74,793,487	71.67 MB

TL tokens	TL characters	TL size
12M	91,352,025	234.6 MB


Dataset top 10 domains

SL domain	Segments	TL domain	Segments
wikipedia.org	10.1%	wikipedia.org	9.1%
bajajfinserv.in	5.3%	bajajfinserv.in	4.7%
educationbro.com	4.0%	wikisource.org	3.8%
onworks.net	3.3%	indianexpress.com	2.1%
vsaduidoma.com	1.8%	educationbro.com	1.8%
adda247.com	1.6%	vsaduidoma.com	1.8%
indianexpress.com	1.6%	adda247.com	1.8%
kurangah.com	1.4%	kurangah.com	1.5%
catholicgallery.org	1.3%	onworks.net	1.3%
jw.org	1.3%	wordplanet.org	1.2%


Dataset top 10 TLDs

SL domain	Segments	TL domain	Segments
com	80.2%	com	66.2%
org	24.8%	org	23.9%
in	9.5%	in	9.2%
net	7.7%	net	3.9%
info	1.6%	rehab	1.2%
rehab	1.3%	top	0.8%
top	0.8%	zone	0.7%
zone	0.8%	gov.in	0.7%
plus	0.7%	info	0.5%
gov.in	0.7%	plus	0.5%

Translation likelihood




Collections

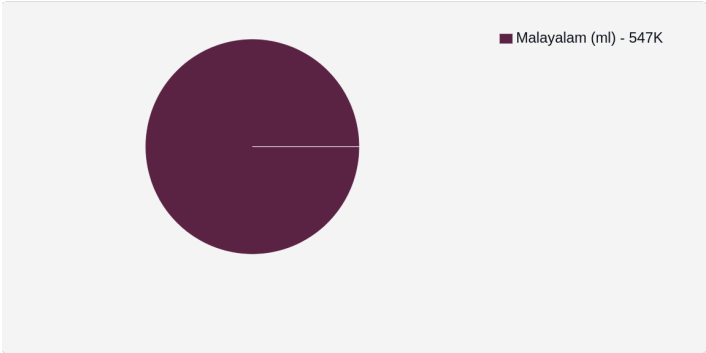


Language Distribution


Source




Target




Source segment length distribution by token



Target segment length distribution by token



Segment pair noise distribution



Source n-grams

Size	n-grams
1	also   26606   said   25901   one   24533   india   22051   new   20968
2	prime minister   5778   personal loan   4118   new delhi   3936   bajaj finserv   3803   chief minister   3784
3	jammu and kashmir   1892   minister narendra modi   1745   prime minister narendra   1731   bin rashid al   1367   mohammed bin rashid   1357
4	prime minister narendra modi   1722   archived from the original   1579   application that can also   1351   bin rashid al maktoum   1348   mohammed bin rashid al   1283
5	also be fetched from https   1351   mohammed bin rashid al maktoum   1281   sheikh mohammed bin rashid al   1019   run online this app named   981   latest release can be downloaded   857

Target n-grams

Size	n-grams
1	ഞങ്ങളുടെ   24000   പുതിയ   18995   പാഞ്ഞു   18666   ചെയ്യുക   13499   അവർ   13288
2	ക്ലിക്ക് ചെയ്യുക   2132   ബങ്കാങ് ഫിൻസെർവ്   2117   ഹോം മൊബ്   1626   ആർലൈവ് ചെയ്യൂത്   1609   ബാങ്ക് ഓഫ്   1608
3	സാങ്കു ഓപ്പറേറ്റീവ് സിസ്റ്റങ്ങളിലൊന്നിൽ   1351   രീതിയിൽ ഓൺലൈനിൽ പ്രവർത്തിപ്പിക്കുന്നതിനായി   1351   പ്രവർത്തിപ്പിക്കുന്നതിനായി ഇത് onworks   1351   ഞങ്ങളുടെ സാങ്കു ഓപ്പറേറ്റീവ്   1351   എല്ലാവരും രീതിയിൽ ഓൺലൈനിൽ   1351
4	സിസ്റ്റങ്ങളിലൊന്നിൽ നിന്ന് ഏറ്റവും എല്ലാവരും   1351   ഞങ്ങളുടെ സാങ്കു ഓപ്പറേറ്റീവ് സിസ്റ്റങ്ങളിലൊന്നിൽ   1351   ഓൺലൈനിൽ പ്രവർത്തിപ്പിക്കുന്നതിനായി ഇത് onworks   1351   എല്ലാവരും രീതിയിൽ ഓൺലൈനിൽ പ്രവർത്തിപ്പിക്കുന്നതിനായി   1351   സാങ്കു ഹോസ്റ്റിംഗ് ഓപ്പറേറ്റീവ് onworks   858
5	സിസ്റ്റങ്ങളിലൊന്നിൽ നിന്ന് ഏറ്റവും എല്ലാവരും രീതിയിൽ   1351   രീതിയിൽ ഓൺലൈനിൽ പ്രവർത്തിപ്പിക്കുന്നതിനായി ഇത് onworks   1351   ഓപ്പറേറ്റീവ് സിസ്റ്റങ്ങളിലൊന്നിൽ നിന്ന് ഏറ്റവും എല്ലാവരും   1351   എന്നതിൽ നിന്നും ലഭിക്കുന്ന ഒരു ആപ്ലിക്കേഷനാണ്   984   സാങ്കുയമായി ഓൺലൈനായി ഡാൺഡോവ് ചെയ്ത് പ്രവർത്തിപ്പിക്കുക   679

About HPLT Analytics

Volumes - Segments

Segments correspond to paragraph and list boundaries as defined by HTML elements (<p>, <ul>, <ol>, etc.) replaced by newlines.

Volumes - Tokens

Tokenized with <https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md>

Type-Token Ratio

Lexical variety computed as \*number or types (uniques)/number of tokens\*, after removing punctuation (<https://www.sitinfo.com/wp-content/uploads/2014/01/type-token-ratio.pdf>).

Document size (in segments)

Segments correspond to paragraph and list boundaries as defined by HTML elements (<p>, <ul>, <ol>, etc.) replaced by newlines.

Language distribution

Language identified with FastSpell (<https://github.com/mbanon/fastspell>).

Distribution of segments by fluency score

Obtained with Monocleaner (<https://github.com/bitextor/monocleaner>).

Distribution of documents by average fluency score

Obtained with Monocleaner (<https://github.com/bitextor/monocleaner>).

Distribution of documents by document score

Obtained with Web Docs Scorer (<https://github.com/pablop16n/web-docs-scorer/>).

Segment length distribution by token

Tokenized with <https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md>

Segment noise distribution

Obtained with Bicleaner Hardrules (<https://github.com/bitextor/bicleaner-hardrules/>).

Frequent n-grams

Tokenized with <https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md>, after removing n-grams starting or ending in a stopword. Stopwords from <https://github.com/hplt-project/data-analytics-tool/blob/main/scripts/resources/README.txt>