HPLT Analytics report

General overview

Corpus	Analytics date	Language
kat_Geor.jsonl.tsv	9/19/2024	Georgian (ka)

Volumes

Docs	Segments	Unique segments	Tokens	Size	Characters
3,335,164	63,722,098	29,708,949 (46.62 %)	1.6B	24.7 GB	10,095,225,458

Top 10 domains

Domain	Docs	% of total
wikipedia.org	248K	7.44
radiotavisupleba.ge	141K	4.24
gancxadebebi.ge	96K	2.89
wordpress.com	69K	2.05
netgazeti.ge	34K	1.03
1tv.ge	28K	0.83
on.ge	27K	0.82
sana.ge	26K	0.78
blogspot.com	26K	0.78
ambebi.ge	26K	0.77

Top 10 TLDs

Domain	Docs	% of total
ge	2.1M	63.33
com	495K	14.85
org	313K	9.38
gov.ge	111K	3.32
net	68K	2.03
edu.ge	51K	1.53
com.ge	34K	1.03
org.ge	21K	0.63
am	16K	0.49
info	15K	0.46

Documents size (in segments)

<= 25 segments **81.67%** (2.7M documents)
> 25 segments **18.33%** (611K documents)

Documents by collection

cc18 (505K)
cc22 (834K)
cc21 (362K)
18 Others (1.6M)

Language Distribution

Number of segments

- Georgian (ka) - 58M
- English (en) - 2.2M
- Italian (it) - 1.4M
- Mingrelian (xmf) - 434K
- German (de) - 325K
- French (fr) - 290K
- Russian (ru) - 208K
- Dutch (nl) - 101K
- Spanish (es) - 97K
- Serbian (sr) - 89K
- 163 Others - 714K

Percentage of segments in Georgian (ka) inside documents

Distribution of documents by document score

score <= 5 - **99.9%** (3.3M documents)
score > 5 - **0.1%** (3.2K documents)

Segment length distribution by token

<= 49 tokens = **24M** segments | **31M** duplicates
> 50 tokens = **8.8M** segments | **3.5M** duplicates

- Unique segments
- Duplicated segments

Segment noise distribution

Too long	0.00 %
Too short	11.38 %
URLs	1.22 %
Bad encoding	0.00 %
Contains PII	0.20 %

Frequent n-grams

Size	n-grams
1	ეს | 5971888 ამ | 5686353 ის | 5099032 არის | 4570049 იყო | 3701223
2	ეს არის | 543370 წყაროს რედაქტირება | 355269 რა ქმა | 306579 მიუხედავად იმისა | 242247 წლის განმავლობაში | 208765
3	განათლებისა და მეცნიერების | 61610 ამა თუ იმ | 61200 ეს არ არის | 60572 ტრანგი და ქართველი | 56155 ბაბარზე იყო ორიენტირებული | 56068
4	ჯინეტის განვითარებისთვის საქართველოში რამდენიმე | 56058 ძირითადად ტრანგუე ბაბარზე იყო | 56058 ტრანგუე ბაბარზე იყო ორიენტირებული | 56058 საქართველოში რამდენიმე არაკომერციული პროექტი | 56058 კომპანია ძირითადად ტრანგუე ბაბარზე | 56058
5	ჯინეტის განვითარებისთვის საქართველოში რამდენიმე არაკომერციული | 56058 ძირითადად ტრანგუე ბაბარზე იყო ორიენტირებული | 56058 კომპანია ძირითადად ტრანგუე ბაბარზე იყო | 56058 განვითარებისთვის საქართველოში რამდენიმე არაკომერციული პროექტის | 56058 წეის ტრანგი და ქართვეი დამფუძნებების | 56052

About HPLT Analytics

Volumes - Segments

Segments correspond to paragraph and list boundaries as defined by HTML elements (<p>, <ul>, <ol>, etc.) replaced by newlines.

Volumes - Tokens

Tokenized with https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md

Type-Token Ratio

Lexical variety computed as *number or types (uniques)/number of tokens*, after removing punctuation (https://www.sltinfo.com/wp-content/uploads/2014/01/type-token-ratio.pdf).

Document size (in segments)

Segments correspond to paragraph and list boundaries as defined by HTML elements (<p>, <ul>, <ol>, etc.) replaced by newlines.

Language distribution

Language identified with FastSpell (https://github.com/mbanon/fastspell).

Distribution of segments by fluency score

Obtained with Monocleaner (https://github.com/bitextor/monocleaner).

Distribution of documents by average fluency score

Obtained with Monocleaner (https://github.com/bitextor/monocleaner).

Distribution of documents by document score

Obtained with Web Docs Scorer (https://github.com/pablop16n/web-docs-scorer/).

Segment length distribution by token

Tokenized with https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md

Segment noise distribution

Obtained with Bicleaner Hardrules (https://github.com/bitextor/bicleaner-hardrules/).

Frequent n-grams

Tokenized with https://github.com/hplt-project/data-analytics-tool/blob/main/tokenizers-info.md, after removing n-grams starting or ending in a stopword. Stopwords from https://github.com/hplt-project/data-analytics-tool/blob/main/scripts/resources/README.txt